

2026 年度 CCF-蚂蚁科研基金申报课题介绍

一、 人工智能（支持金额不超过 30 万元/项）

1. [面向 AI Agent 记忆系统的时序感知向量检索技术研究](#)
2. [基于长上下文感知与多智能体协同的研运一体化（DevOps）风险根因分析研究](#)
3. [基于对抗机制的 SRE agent 的 Agentic RL 研究](#)
4. [Agent-Skills 在国际复杂业务场景下的自进化交互攻关研究](#)
5. [面向智能助手的小程序自动执行智能体算法研究](#)
6. [面向行业的多智能体自进化上下文技术研究与应用](#)
7. [全模态用户意图理解与工具调度技术研究](#)
8. [面向大规模金融知识图谱构建的实体消解和链指技术研究](#)
9. [面向专家级投研大模型的多源异构深度逻辑语料预处理技术研究](#)
10. [基于结构化交易数据的基座模型研究](#)
11. [基于大模型驱动的通用语义表示体系研究与应用](#)
12. [多模态记忆理解与检索系统的研究](#)
13. [面向前端领域的多模态多任务推理大模型研究](#)
14. [面向下一代智能助手的多模态实时交互算法研究](#)
15. [基于多模态理解与行为序列感知的端到端生成式搜索大模型研究](#)
16. [基于全域数据的生成式推荐统一建模研究](#)
17. [基于扩散对齐与约束高斯泼溅的可控 3D 数据生产关键技术研究](#)
18. [多模态高质量数据合成方法的研究](#)
19. [具身场景下的单目 4D 重建与理解的空间智能研究](#)
20. [百万级数据资产智能检索与需求对齐技术研究](#)
21. [针对强化学习场景的混合线性模型推理优化研究](#)
22. [基于观测数据的风险响应算法研究](#)
23. [规约驱动的可信智能编程框架：融合领域知识注入与检索增强的幻觉抑制研究](#)

24. [基于博弈论的信用系统防共谋机制研究](#)
25. [AI 眼镜音频相关技术研究](#) (备注：本课题支持金额不超过 50 万元)

二、超算与智算（支持金额不超过 30 万元/项）

1. [软硬协同的大规模 KVCache 系统](#)
2. [面向多模态模型视觉的 Token 压缩](#)
3. [基于高效显存分配和 SLO-aware 请求调度的大规模 LLM 推理服务系统](#)
4. [基于 Compute Express Link \(CXL\) 的智能计算系统架构优化与资源池化技术研究](#)
5. [通信计算 Overlap 自动编排框架](#)
6. [大规模异构场景大模型推理 serverless 调度优化](#)
7. [通智算融合场景下节点健康评估模型研究](#)

三、网络空间安全与隐私保护（支持金额不超过 30 万元/项）

1. [基于大模型的自动化威胁验证技术研究](#)
2. [面向多模态触发与动态植入的大模型后门防御技术研究](#)
3. [大模型防蒸馏对抗与核心知识资产动态防护技术研究](#)
4. [智能化多语言程序分析关键技术研究](#)
5. [零知识证明友好的分组密码设计](#)
6. [面向区块链资产安全的智能体驱动型安全分析与风险治理研究](#)
7. [面向复杂技术生态的自适应隐私数据检测系统研究](#)

四、软硬协同（支持金额不超过 40 万元/项）

1. [基于 GPU 的多密钥 CKKS 加速](#)
2. [基于多 GPU 的 FHE 加速](#)
3. [面向同态加密的 CSD 功耗-性能协同优化方法](#)
4. [面向全同态密文大模型推理的超节点异构近数据计算系统](#)
5. [端云协同的同态加密、转密和解密计算性能优化](#)

一、 人工智能（支持金额不超过 30 万元/项）

1. 面向 AI Agent 记忆系统的时序感知向量检索技术研究

研究背景

随着 LLM 驱动的自主 Agent 从单轮问答向长期交互演进,持久化记忆已成为支撑 Agent 上下文连贯性与持续学习的核心能力。Agent 需要从跨越数天乃至数月的多轮对话与事件流中,按时间维度精确地存储、检索与推理信息。时序感知的向量检索作为连接高维语义空间与时间序关系的桥梁,直接制约着 Agent 记忆系统的能力上限。

然而,当前主流 ANN 算法(HNSW、IVF-PQ 等)均建立在静态度量空间假设之上,将语义相似性视为时间无关的不变量。这与现实中知识随时间演化的本质相矛盾:同一实体在不同时间点的语义表征可能截然不同,同一语义片段的检索价值也随时间非均匀衰减。评测数据显示,现有系统在时序推理类问题上的准确率显著低于事实检索类问题(如 MemX 系统时序推理 Hit@5 仅为 43.6%),揭示了语义检索与时序推理之间的结构性鸿沟。

业界已有多种尝试但均存在局限:Zep/Graphiti 等时序知识图谱方案依赖 LLM 实时抽取三元组,计算开销高且误差累积;SpatCode 等统一编码方案将时空信息嵌入旋转相位,但异质维度压缩的理论可行性边界尚不清晰;FadeMem 等生物启发式衰减机制的参数设计依赖经验调优,缺乏理论最优性保证。

综上,时序感知向量检索在理论与系统两个层面均面临根本性挑战:理论上缺乏融合时间偏序关系与衰减语义的统一数学框架,系统上缺乏支持时序索引动态维护与语义-时序联合排序的高效方案。本课题聚焦以下两个核心问题:

(1) 时序-语义联合度量空间的理论构建与高效索引研究:如何定义融合语义距离与时序距离的联合度量函数,分析其在不同衰减模型下的拓扑性质与近似搜索界?如何在 HNSW/IVF 框架内将时间作为一阶索引特征,设计时间窗口剪枝策略?如何利用时序局部性设计自适应多层索引,对热数据保持高精度、对冷数据渐进压缩?

(2) 面向 Agent 记忆的动态时序知识管理与检索机制研究:如何设计增量式索引维护算法并支持双时态查询?如何建立记忆重要性与时序衰减的统一评估模型,并证明遗忘策略的竞争比界?如何融合向量检索与时序知识图谱,设计"向量召回-图谱推理"的级联检索架构?

预计产出

- 1) 报告:提交项目结题表,提交结项验收报告。撰写一份《面向 AI Agent 记忆系统的时序向量检索技术白皮书》,系统阐述理论框架、算法设计与最佳实践。
- 2) 论文:投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录,提供论文底稿及收录邮件。
- 3) 专利:乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1-2 项,交付符合本项目创新点的专利申请号和专利申请相关材料(内容针对时序-语义联合度量空间构建方法及自适应多层时序索引结构)

- 4) 算法原型：开发一个开源的时序感知向量检索引擎原型，包含时序-语义联合索引模块、自适应衰减模块与级联检索接口，并在 LongMemEval 等标准基准上提供详细的性能评测报告。
- 5) 技术指标：研究基于时序-语义联合度量空间与自适应多层索引方法，提升 AI Agent 长程记忆系统的时序感知检索准确率，形成融合向量检索与时序知识图谱的级联检索架构及开源原型引擎。探寻适用于大规模 Agent 持续交互场景下非平稳事件流的高效记忆存储、衰减与检索机制。在开源数据集（LongMemEval 等）上时序推理类任务的检索准确率（Hit@5）提高 15%，在蚂蚁集团工作记忆场景落地，与现有算法相比端到端检索延迟平均缩短 40%。

[返回首页](#)

2. 基于长上下文感知与多智能体协同的研运一体化(DevOps)风险根因分析研究

研究背景

随着软件系统向云原生、微服务、持续交付架构演进，研运一体化（DevOps）流程日益复杂，其数据呈现出“跨域（Cross-Domain）”、“海量（High-Volume）”和“长上下文（Long-Context）”的三大特征。风险与故障的根因往往隐藏在代码提交、CI/CD 流水线、容器部署、服务监控、日志告警等多个环节的复杂交互之中。

现有的风险分析方法面临两大瓶颈：

- 1) 协同分析困境：传统单点工具或孤立的 AI 模型难以打通研发与运维的数据壁垒，无法应对跨阶段、跨系统的级联故障，导致“告警风暴”和“定位困难”。
- 2) 上下文理解瓶颈：大语言模型（LLM）虽在代码分析等任务中表现出色，但其有限的上下文长度使其在处理大型代码库、复杂调用链或海量日志时“只见局部、难见全局”，同时高昂的 Token 成本也限制了其在真实场景中的广泛应用。

为解决上述挑战，本项目创新性地提出一个“宏观协同”与“微观深潜”相结合的智能风险根因分析框架。该框架以多智能体系统（Multi-Agent System）为宏观协同骨架，为 DevOps 各环节（编码、构建、测试、部署、运维）分配专属智能体；同时，以长上下文优化技术为微观分析核心，赋能各智能体深度理解其负责领域内的复杂数据（如长代码、长日志），最终实现对 DevOps 全生命周期风险的快速感知、精准溯源与智能决策。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：完成一套集成长上下文感知与多智能体协同的风险根因分析算法原型。核心交付物是一套面向 DevOps 各环节的角色化 Agents，它们是封装了角色特定逻辑、工具调用能力和底层大模型的核心功能单元。同时，交付支撑这套智能体系统运行的协同推理引擎与长上下文语义压缩模块，并提供完整的源代码及部署文档。
- 5) 技术指标：围绕准确性、效率与成本设定关键指标：在公开数据集上，实现故障根因定位 Top-3 准确率提升 30%以上；在 Antcode 场景中，通过长上下文优化技术将代码分析的 Token 消耗降低 70%；最终在 Derisk 平台落地，将自动化根因分析的平均定位时间（MTTD）与现有流程相比缩短 50%以上。

[返回首页](#)

3. 基于对抗机制的 SRE agent 的 Agentic RL 研究

研究背景

本研究旨在构建一个基于对抗博弈的 SRE 智能体自进化系统。该系统包含两个核心智能体：一个“故障注入 Agent”，负责在仿真环境中动态生成多样化、高难度的故障场景；另一个“根因诊断 Agent”，基于 Agentic RL 技术学习分析海量数据以快速定位根因。通过让两个智能体进行大规模的自我对弈，它们将在“攻防”中相互驱动、共同进化，最终锤炼出一个能力强大的自动化诊断模型，以解决高质量训练数据稀缺的难题，并实现对真实故障的高效、精准定位。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：完成 Adversarial Agentic RL 的算法设计，产出满足时效&性能的 agent。
- 5) 技术指标：RCA 准确率达到 80%，训练完了以后 agent 总体 token 消耗量相对于线上未训练的 agents 减半。

[返回首页](#)

4. Agent-Skills 在国际复杂业务场景下的自进化交互攻关研究

研究背景

国际业务复杂风险分析与合规审查流程呈现出显著的多维复杂性特征,表现为跨系统集成、跨地域合规、多语言环境及异构规则体系的交织。风控人员需在多套核心业务平台间频繁切换,执行包括多源信息核实、复杂材料萃取、跨表单字段比对及全链路证据留存等高负载操作。现有的流程自动化工具难以应对非标准、动态变化的国际业务场景,亟需具备高度自主性的智能决策支持。

大语言模型与多模态大模型在环境理解与任务规划方面展现了巨大潜力。然而,智能体 Agent 在复杂业务中稳健落地的核心,在于其能否构建一套可表示、可迁移、可组合、可优化的 Agent-Skills 体系。只有实现从“单次任务执行”向“可持续演进的技能管理”跨越,智能体才能真正吸收专家经验,实现多场景业务的稳定支撑。

现有智能体在 Agent-Skills 构建与演化方面仍存在明显不足:

- 1) Skill 构建较为主观,自动生成效率低且复用成本高,难以适应跨场景、跨任务、跨规则的复杂应用场景;
- 2) 在复杂 Agent 交互及 Multi-Agent 协同场景,当前仍缺乏高效、稳定的强化学习方法,难以支撑 Agent 性能的持续优化;
- 3) 国际业务数据来源复杂、结构杂乱、上下文链路长,导致 Agent 的 Memory 管理与上下文组织难度较大,成为制约大模型持续迭代与实际落地的重要瓶颈。

预计产出

- 1) 报告:提交项目结题表,提交结项验收报告。
- 2) 论文:投稿 CCF-A 类及蚂蚁认可的期刊/会议论文至少 1 篇并最终收录,提供论文底稿及收录邮件。
- 3) 专利:乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项,交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型:交付 1 套代码模型,形成可复用的多模态数据集与工具链,支撑后续科研与工程应用。
- 5) 技术指标:交付的代码模型框架可以落地至少 2 个业务场景,风险调查准确率提升 20%。

[返回首页](#)

5. 面向智能助手的小程序自动执行智能体算法研究

研究背景

数字世界的信息和服务具有极高的多样性与复杂性,如何在数字世界中快速精准地获取信息或服务成为下一阶段人机交互方式变革的主要目标。为此,行业内涌现出 `operator`、`computer use`、`browser use` 等方案致力于建设数字世界中的具身智能,希望通过智能操作 PC、手机等方式提升用户获取服务/信息的效率与体验。

在小程序侧,复杂的业务逻辑、多样的功能供给在一定程度上增加了用户的使用门槛,用户往往需要花费较多时间理解服务功能与操作,才能完成自身需求。为此,需要快速建设移动端服务自动导航与执行能力,改变用户的交互方式。

预计产出

- 1) 报告:提交项目结题表,提交结项验收报告
- 2) 论文:投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录,提供论文底稿及收录邮件。
- 3) 专利:乙方协助蚂蚁和/或其关联公司提交国内、国际专利不少于 1 项,交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型:完成高精度高智能化算法方案设计,交付一套具备智能、多环境自适应性能的服务自动执行框架、模型、源码。
- 5) 技术指标:服务自动执行任务完成率 95%; UI 智能体在小程序生态内的 90%的服务支持智能化的自动执行,在效率与现有算法相比平均缩短 30%,效果上提升 50%

[返回首页](#)

6. 面向行业的多智能体自进化和上下文技术研究与应用

研究背景

支付宝 AI 应用正在步入“从答复到办结”的新阶段，这意味着 AI 不仅需要处理单次问答，更需要在超长会话和复杂任务流中，持续对齐用户意图并形成可执行的决策与动作。当前随着 Super Agent（超级智能体）的演进，系统的上下文管理与 Memory 机制面临严重的效能瓶颈：海量交互导致的长上下文爆炸不仅引发大模型“中间遗忘”与推理成本剧增，且记忆碎片化难以形成连贯的用户画像。同时，传统产研协作在应对需要复杂上下文穿透的业务需求时，陷入海量重复性工作（如大量点状 Badcase 的诊断与修复）。

为应对指数级增长的业务需求与大模型深水区挑战，我们需探索以高性能上下文技术为核心的自进化系统。系统结合长短上下文记忆，自动完成意图理解拆解、异构工具（Skill）捞取与 workflow（DAG）动态编排，生成可帮助用户“办结”的 Agent（数字员工），重构系统的底层记忆与计算流。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1-2 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：完成不少于 1 种新型高效长上下文处理的算法设计（包含源代码，权重等 checkpoint）。完成不少于 1 种新型智能体编排调度与自进化算法设计。构建并开源 1 个评估数据集 Benchmark。交付一套面向特定业务场景（如自动化 Agent 构建）适用的验证框架。
- 5) 技术指标：研究基于长上下文管理与分层 Memory 引擎，探寻适用于行业业务属性的系统自进化技术。在蚂蚁和/或其关联公司超级 AI 员工场景落地，形成具有行业影响力的技术白皮书。

[返回首页](#)

7. 全模态用户意图理解与工具调度技术研究

研究背景

在政务助手、就业 AI、出行助手产品优化过程中，传统的问答能力已难以满足用户当前需求。如今的 AI 不仅需要提供问答，更要能帮助用户便捷地完成实际操作与办结。为具备此能力，并结合支付宝丰富的现有服务供给，行业需探索全模态 Agent。它能通过整合用户输入的语音、截屏、图片、视频和文字，结合用户的全模态记忆（Memory），精准调用个性化工具与服务。这有助于提升全模态大模型的理解与规划能力。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：提出不少于 1 种新型全模态 Agent 架构、模型结构或模型训练方法的改进方案。交付 1 个面向特定业务场景的全模态 Agent 算法系统。
- 5) 技术指标：基于对中文 app 屏幕理解，在全模态场景结合长文本结构化理解与推理构建新的训练集，提升长尾多模态 Agentic Planning 准确率 5%。

[返回首页](#)

8. 面向大规模金融知识图谱构建的实体消解和链指技术研究

研究背景

随着金融搜索、金融大模型、投研投顾和智能风控等业务快速发展，高质量金融知识图谱需求迫切。需从千万级研报和百亿级财经网页中构建覆盖实体及关系的超大规模图谱。但金融数据来源复杂（多模态、非结构化、OCR 噪声多、跨源不一致），实体识别、消解与链指直接影响图谱质量和下游应用效果。现有方法在金融场景下存在三大不足：

- 1) 缺乏统一的多模态实体建模能力，无法融合文本、图表、版面等协同信息；
- 2) 大规模高精度消解与链指计算开销大、延迟高，难兼顾离线构建与在线检索；
- 3) 对金融实体名称、组织关系及事件语境的频繁变化适应性差，鲁棒性、可扩展性和时效性不足。因此，研究面向大规模金融知识图谱的实体消解与链指技术具有重要理论与现实意义。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1-2 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：能够应用到包括金融搜索、金融大模型等蚂蚁业务场景的核心技术，沉淀可工作的算法和系统 demo 代码和相关的研发文档。
- 5) 技术指标：研究基于多模态金融数据的实体消解与链指技术，提升多模态实体消解与链指技术的覆盖率和准确率，支撑金融搜索、金融大模型等核心业务场景。在业务数据上与现有算法相比在保证高覆盖率情况下精度提高 10%，在开源数据集上超过现有 SOTA，交付可工作的算法和系统 demo 代码及相关研发文档，协助团队沉淀围绕大规模金融知识图谱构建的算法和系统能力。

[返回首页](#)

9. 面向专家级投研大模型的多源异构深度逻辑语料预处理技术研究

研究背景

随着大模型向垂直领域纵深发展，打造具备“专家级投研能力”的金融基座模型（如投研版 Claude）已成为资管与券商机构的核心诉求。然而，真实的投资研究高度依赖深度逻辑推理与多维数据的交叉验证。现有的通用语料清洗方法无法处理投研场景中特有的复杂数据形态，如长篇深度研报中的嵌套财务表格、财报电话会（Earnings Calls）中的多轮专业问答、以及研报文本与财务数据之间的隐含逻辑关联。由于投研语料充斥着复杂的金融术语且对事实准确性要求极高，传统解析极易造成大模型的“逻辑断裂”或“数字幻觉”。本项目旨在联合高校顶尖 AI 力量，攻克投研级复杂文档解析与投资逻辑语料重构难题，构建一条高信噪比、强逻辑关联的专属语料预处理管线，为训练真正能辅助分析师决策的“AI 投研助手”铸造数据底座。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利至少 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料（围绕复杂财务表格解析、投研观点抽取、金融逻辑一致性校验算法等核心创新点）。
- 4) 算法原型：交付一套端到端的投研语料自动化预处理与打标系统（包含研报解析、逻辑校验、指令生成模块）及完整源代码。
- 5) 技术指标：复杂财务报表（如三大表）的结构化提取准确率（TEDS 指标）不低于 95%；研报中“图表-正文”引用关系的对齐准确率达到 90%以上。

数据产出（预训练+微调）：

- 交付不少于 50GB 经过深度清洗与去重的纯净投研预训练语料（如涵盖过去 5 年核心券商研报、宏观数据、财报会议录音转写等）。
- 交付不少于 10 万条高质量的“投研逻辑推理”指令微调数据集（QA 对），数据需经过人工抽检，逻辑自洽率> 95%。

[返回首页](#)

10. 基于结构化交易数据的基座模型研究

研究背景

在全球化贸易与跨境消费持续深化的背景下，国际卡支付已成为连接全球市场、促进资金跨境流动的核心基础设施，其业务覆盖线上电商购物、线下跨境商旅、企业间跨境结算等多元场景，日均交易规模达数十亿笔，涉及用户、商户、交易终端、发卡行、收单行、国际卡组织等多类实体。

在这一复杂场景中，风险防控是保障国际卡支付体系安全稳定运行的核心环节，黑产往往通过分散化的用户账号、关联化的商户网络、跨地域的终端布局伪装成正常交易，传统风控模式依赖人工排查单条交易记录或孤立分析用户行为，不仅难以捕捉实体间的隐性关联，更面临“人力成本高（单条风险线索排查需数小时）、响应效率低（欺诈发生后数天才能追溯源头）、误判率高（正常跨境消费易被误拦截）”的三重困境。

随着大语言模型（LLM）单模态文本能力渐入瓶颈，多源异构数据的高效整合成为解锁 AI 跨模态认知的关键挑战。金融风控、工业物联网等场景中，数据天然具备多源（数据库/传感器/图谱）与异构（表格/时序/图文）特性，而现有技术面临三重困境：1）非文本数据“语言化”依赖人工规则，导致语义扭曲与特征丢失；2）大模型架构僵化，无法动态融合多模态信息；3）长上下文处理低效且任务适配不足。解决这些问题需突破跨模态表征对齐、动态输入架构、层次化训练等关键技术，其突破不仅将释放大模型的通用认知潜力，对应复杂现实挑战也具有战略意义。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：一套在风控生产环境可落地的模型方案
- 5) 技术指标：基座模型能够在实时风险防控覆盖率上提升 30%，该基座模型可以落地至少 2 个业务场景。

[返回首页](#)

11. 基于大模型驱动的通用语义表示体系研究与应用

研究背景

支付宝作为综合 App，供给包括了电商、服务、小程序短视频、直播、生活服务、金融资讯、本地生活等的超级生态。用户在不同的场景会留下丰富的行为，如在 Tab3 内产生播放、点赞、评论、转发等互动行为；首页有诸如闪购、电商、生活号、小程序、搜索、支付结果页等多个触点留下隐式或显式反馈。不同的供给的融合了文本、视频、商品、服务、账单等多模态多源异构信息体系。当前推荐系统仍依赖传统 ID 化特征（如 user_id、item_id）和孤立的行为序列建模，难以有效打通“人-供给-场景”之间的语义鸿沟，导致兴趣建模碎片化、冷启动效果差、跨域迁移能力弱等问题，制约了内容分发效率与用户体验的进一步提升。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：提出一种异构题材的统一 tokenizer 方案，基于全域统一的异构表征体系，设计长序列跨域异构建模方案增强模型表现，并结合业务场景设计下游推荐场景构建全域统一推荐模型基座大模型，提升对应下游场景业务指标。
- 5) 技术指标：项目成果将直接落地于首页双列及核心电商等复杂业务场景，预期驱动业务侧点击页面浏览量（Click PV）相对提升 3%以上，核心模型命中率（Hitrate）较现有基线提升 10%以上。

[返回首页](#)

12. 多模态记忆理解与检索系统的研究

研究背景

随着人工智能应用的交互方式升级，近年来多模态+环境感知的交互方式越来越常见，多模态信息理解能力已成为关键基础设施。我们的场景为记忆系统，需要能对多模态信息进行理解、存储、检索。然而，当前真实场景中的应用仍面临两大核心挑战：一是多模态信息的处理与计算效率存在显著瓶颈；二是多模态信息理解过程中出现的幻觉现象及其可靠性问题亟待解决。

与此同时，以 FARS (Fully Automated Research System) 和 ARIS (Auto-Research-In-Sleep) 为代表的新一代 AI 科研自动化系统，正在重塑科学研究范式——从"人工驱动"向"智能体自主驱动"演进。

本课题旨在构建基于多模态图文记忆理解与推理系统，并期望探索出一套系统能打通自动科研验证的技术闭环，通过应用 agentic 能力更好、更快的对多模态记忆理解与检索系统进行优化。

核心问题

1) 长上下文多模态建模与动态推理能力不足

用户交互中常伴随多轮图文交互（如上传图片+补充文字+点击反馈），现有多模态模型在识别的时候存在一定的幻觉率、对序列型多模态信息的推理缺乏较好的连续推理能力。

2) 多模态模型的高资源消耗

多模态大模型往往参数量庞大，推理延迟高、显存占用大，如何通过模型蒸馏、稀疏化、硬件协同优化等手段实现"高性能-低延迟-低成本"平衡，是商业化落地的核心制约因素。

3) 科研效率瓶颈：从"想法"到"验证"的周期过长

传统 AI 科研流程高度依赖人工：文献调研→Idea 构思→实验设计→代码实现→结果分析→论文撰写，单个实验验证周期往往长达数周甚至数月。如何借鉴 FARS 和 ARIS 的先进理念，构建面向 Memory 领域的自动科研系统，实现"想法生成-实验执行-结果分析-论文产出"的全链路自动化，是提升科研效率的关键突破口。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1-2 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：交付 1 套面向多模态 Memory 领域的全链路自动化实验系统
- 5) 技术指标：多模态记忆场景识别准确率 J 分提升 5%，图片识别幻觉率不超过 3%

[返回首页](#)

13. 面向前端领域的多模态多任务推理大模型研究

研究背景

随着人工智能技术的飞速发展，大模型正逐步从通用能力向垂直领域专业化演进。在人机交互日益依赖图形用户界面（GUI）的今天，前端开发作为连接用户与数字服务的核心环节，其智能化水平直接影响产品体验与开发效率。然而，当前主流大模型在前端领域仍面临三大挑战：

- 1) 缺乏高质量、结构化的多模态前端数据集（如 UI 截图、代码、设计规范、交互历史等）；
- 2) 模型对 UI 元素的理解、生成与推理能力不足，难以支撑复杂任务如界面重构、自动评测、智能修复等；
- 3) 现有模型多为通用架构，缺乏针对前端领域任务（如基于 Ant Design 等主流框架的组件识别与生成）的定制化设计。

蚂蚁集团长期深耕前端工程体系，开源了 Ant Design（AntD）等业界广泛采用的 UI 框架，并在 UI 领域的视觉模型/大模型/Agent、低代码平台等领域积累了一定的业务场景与数据资源。为推动前端智能化迈入新阶段，亟需联合学术界力量，构建面向前端领域的垂直专家大模型，突破多模态理解与生成的技术瓶颈，实现从前端感知到智能决策的全链路能力升级。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1-2 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：
 - 构建可部署的多场景推理引擎，支持 B/C 端混合输入（图像、文本、原型图）。
 - 发布首个开源的前端领域多模态数据集 Frontend-MM，覆盖移动端、Web 端等主流场景。
 - 在 Hugging Face、ModelScope 等平台发布模型与工具链。
- 5) 技术指标：开源前端专家大模型，具备多任务推理能力。在 UI 理解、生成、推理、评等子任务上持续突破，达到 SOTA 水平。

[返回首页](#)

14. 面向下一代智能助手的多模态实时交互算法研究

研究背景

随着原生多模态大模型技术的飞速发展，传统基于图形用户界面（GUI）的交互范式也在快速迭代，通过语音/视频及生成式 UI 的交互方式成为更自然的交互方式。然而，当下的 AI 原生应用基于文字 or 语音的模态交互，在端到端的交互体验上仍然存在提升空间：

- 1) 基于音视频的实时交互仍然面临较大的功能&性能体验问题；
- 2) 输出环节仍以语音为主，缺少面向实时交互的多模态输出能力。支付宝作为国民级应用，为用户提供低门槛、高质量的交互能够显著提升用户使用体验，是其在 AI 智能化升级的过程中需要重点投入的技术课题。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：完成实时多模态交互的算法设计，交付一套支持实时音频+视频问答系统原型。
- 5) 技术指标：在开源多模态对话数据集（如 Full-Duplex-Bench-v2 等）上打断时机预测及跨模态对齐精度提高 5%~10%，探寻适用于多模态智能助手或实时音视频交互场景落地方案，与现有算法相比端到端系统首字/首帧响应耗时平均缩短 30%~40%。

[返回首页](#)

15. 基于多模态理解与行为序列感知的端到端生成式搜索大模型研究

研究背景

端到端生成式搜索已取得突破性进展，但仍面临以下几类问题：

- 1) 传统搜索分阶段优化，QP-召回-相关性-排序，训练目标不一致，降低搜索上限；最新的端到端生成式搜索系统虽实现了统一建模，但处在起步阶段，探索空间巨大；
- 2) 多模态信息理解缺乏，常规搜索以文本为主，供给侧丰富的图片、视频、语音等也是重要信息的补充来源；
- 3) 行为序列感知&用户个性化刻画，客观世界的搜索意图动态变化，结合用户行为实现个性化、千人千面的智能化搜索系统，是需要长期探索的难题；

在此背景下，本项目旨在通过和高校合作，构建一套基于多模态理解与行为序列感知的端到端生成式搜索系统来缓解上述痛点问题。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件。论文内容应围绕以下方向展开，包括但不限于：
 - 多模态理解的端到端个性化生成式搜索方法；
 - 统一检索、理解、生成与排序的一体化搜索框架；
 - 面向实际搜索场景的生成式搜索建模与优化方法。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1-2 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：
 - 完成基于多模态理解与行为序列感知的端到端生成式搜索系统的算法设计与系统实现，交付一套适用于搜索场景的端到端生成式搜索算法原型系统，以及相关源代码、模型权重、训练脚本、推理脚本和关键 checkpoint。
 - 在蚂蚁和/或其关联公司业务场景中，完成上述端到端生成式搜索系统在支付宝搜索的落地验证，有搜索规模，搜索发起率，搜索点击率等核心指标上有置信提升，并至少完成推全一次。交付内容包括：落地方案、实验配置、上线验证结果、效果分析报告及复盘总结材料。
- 5) 技术指标：研究基于多模态语义理解、用户行为序列感知建模与检索增强生成的方法，提升搜索场景下复杂查询意图识别、跨模态内容匹配与生成式答案生成的准确率，形成面向搜索业务的端到端生成式搜索大模型技术方案。探寻适用于通用搜索、内容搜索及商品搜索场景的生成式搜索模型训练与应用方法。在评测集上 NDCG@10、Recall@50、MRR 等核心指标提升 5%~10%，在蚂蚁和/或其关联公司搜索场景落地，与现有算法相比用户获取有效结果的平均时长缩短 5%，复杂长尾查询场景下的结果满意度提升 10%以上。

[返回首页](#)

16. 基于全域数据的生成式推荐统一建模研究

研究背景

生成式推荐目前在各个互联网公司（包含蚂蚁）都证明具备一定的业务价值和潜力，基于优越的生成能力，把 item token 和 action token 进行交错组织，能实现召回和排序两类任务统一。然而现有的生成式推荐，都只在单个场景证明有效，当进一步拓展到全域的多个场景，需要解决更加复杂的技术难点。

- 1) 第一个难点是目前生成技术，还主要是依赖 ID 特征作为主要序列，泛化性不足，需要考虑引入多模态等泛化性强的信号；
- 2) 第二个难点是全域的场景，不同场景之间的 action 是异构的，比如有的是点击，有的是时长，需要模型具备较强的适配能力；
- 3) 第三个难点是长序列，拓展到全域数据后，用户序列会大大增加，并且考虑文本化和多模态信息的情况下，序列的长序会进一步增加，需要同时考虑性能和效果。需要探索有效的新技术来解决这三个难点。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1-2 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：完成生成式推荐的算法设计，交付一套包含协同信息融合的异构特征与协同信息融合的物品符号化技术、推荐任务导向的新型生成式网络架构和面向 Top-K 指标的生成式模型优化算法的技术框架，及其源代码。
- 5) 技术指标：提出生成式推荐统一建模范式，在开源亚马逊数据集上相比于 TIGER 等当前主流的生成式推荐方法 AUC 性能提升超 0.5%。并推动研究成果在在蚂蚁和/或其关联公司推荐场景落地。

[返回首页](#)

17. 基于扩散对齐与约束高斯泼溅的可控 3D 数据生产关键技术研究

研究背景

当前 3D 内容生成领域虽已引入扩散模型先验，但仍面临几何-语义不一致、推理效率低下及可控性不足的核心挑战。具体表现为：

1) 几何与语义错位：现有方法难以在稀疏视角下实现几何结构与语义信息的鲁棒对齐，导致生成资产在多视角下出现伪影或结构坍塌；

2) 生成过程不可控：难以通过多模态指令（文本/草图）对生成细节进行精确的迭代修正与约束；

3) 推理与动态受限：传统 3D 生成推理步数多、速度慢，且缺乏物理约束，难以满足实时交互与动态场景需求；

本项目旨在攻克扩散先验与 3D 高斯泼溅的深层对齐难题，建立一套高效、可控、物理一致的 3D 合成算法范式，为下游任务提供高保真且轻量化的 3D 资产。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1-2 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：
 - 完成基于扩散 Transformer 与 3DGS 融合的生成算法设计，重点解决几何一致性、语义对齐与推理效率问题；
 - 语义-几何鲁棒对齐：设计几何与语义联合优化损失，在稀疏输入条件下实现 3D 资产的结构完整性。确保生成资产的几何拓扑与语义标签（如部件类别、材质区域）在空间上严格对齐，解决多视角不一致难题。
 - 高效推理与动态约束：将推理步数压缩至极少步数，显著提升生成速度；同时引入物理/动态约束模块，确保静态资产在动态仿真中的物理合理性（如碰撞体积、形变限制）。
 - 紧凑化 3D 表示：在保持视觉高保真（PSNR/SSIM）的前提下，通过剪枝与量化技术将 3DGS 资产体积压缩至原有水平的 50% 以下，满足端侧实时加载与推理需求。
- 5) 技术指标：在主流数据集上，SSIM / PSNR / 推理速度等指标达到 SOTA。

[返回首页](#)

18. 多模态高质量数据合成方法的研究

研究背景

随着多模态大模型、生成式 AI 和智能体技术快速发展，高质量多模态数据已成为模型训练与应用落地的关键基础。但当前真实数据采集成本高、长尾样本稀缺、人工标注负担重，难以满足复杂场景需求。现有多模态合成方法仍面临跨模态语义一致性不足、模型自举训练导致分布坍塌、长尾与边缘案例覆盖不足、模态组合策略不清晰、自动标注能力弱、坏样本难识别以及评估指标与下游任务脱节等问题。特别是在基于 Agents 的复杂推理轨迹数据和多模态代码数据方面，高质量合成能力仍显不足。为此，有必要开展多模态高质量数据合成方法研究，重点突破一致性约束、多样性增强、长尾定向生成、自动标注与反馈优化、任务导向评估等关键技术，形成可支撑多模态模型训练和智能体应用的数据合成方法体系。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际发明专利 1-2 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：
 - 形成一套面向多模态大模型与智能体应用的高质量数据合成方法体系，突破跨模态语义一致性控制、模型坍塌抑制、长尾样本定向生成、自动化标注、坏样本识别与反馈优化等关键技术，建立合成数据正确性、有效性与完备性的评估方法。交付源代码、权重等 checkpoint。
 - 围绕基于 Agents 的复杂推理与轨迹数据、多模态代码数据两个重点方向，形成可复用的合成流程、标杆数据集和原型工具，验证合成数据对模型理解、推理、生成和执行能力提升的有效性。

[返回首页](#)

19. 具身场景下的单目 4D 重建与理解的空间智能研究

研究背景

本课题面向室内动态场景中智能硬件对环境理解与人机交互能力升级的需求，聚焦单目场景下的 4D 重建与空间智能理解关键问题开展研究。针对现有静态 3D 重建与空间识别方法主要停留在对场景几何结构和物体分布的瞬时感知层面，难以准确、鲁棒地刻画动态环境中物体状态变化、人-物交互过程及场景时序演化规律等问题，课题拟在三维空间建模基础上引入时间维度，构建兼具高精度 4D 重建、时序动态理解与空间智能推理能力的统一方法框架，实现对室内环境中物体变化、空间关系演化、交互事件发生过程及其上下文信息的连续感知、稳定建模与统一表达。

课题重点提升单目条件下 4D 重建结果的准确性、时空一致性与鲁棒性，面向动态场景的 4D 空间智能理解能力，包括对关键物体、空间关系、场景状态、行为过程及变化趋势的综合建模，提升系统在空间理解、时序理解、空间推理与交互语义解析等方面的能力。通过从“看见空间”向“理解空间变化与交互逻辑”升级，在兼顾推理效率与硬件适配的前提下，推动智能硬件从被动感知走向具备上下文感知、行为理解和主动响应能力的空间智能体。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1-2 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：完成 4D 重建理解系统算法设计，交付一套适用于单目场景和/或便携式硬件的 4D 重建与交互理解算法框架，以及相关源代码、模型权重、checkpoint、配置文件和技术文档。
- 5) 技术指标：研究基于 4D 重建与理解的方法，提升空间动态场景的理解能力与重建精度，形成适用于室内场景、兼顾响应速度、物体识别准确性与动态重建能力的系统性技术方案。在已有开源数据集上，相关核心指标达到 SOTA 水平或接近 SOTA 水平；在蚂蚁和/或其关联公司智能硬件场景中完成落地验证，并满足以下指标要求：动态场景重建准确率不低于目前开源业界 SOTA；空间关键物体检测/识别准确率不低于 90%；典型人-物交互事件识别准确率不低于 80%；单路输入条件下，单次推理平均响应时间不高于 500ms。

[返回首页](#)

20. 百万级数据资产智能检索与需求对齐技术研究

研究背景

随着蚂蚁有效数据资产规模突破百万张表，"找表难"已成为数据研发效率的首要瓶颈。传统的基于关键词的元数据搜索（如表名模糊匹配）无法理解业务语义，导致分析师平均需要小时级甚至天级才能定位到所需数据资产。真实的找表场景高度依赖语义推理：用户说"最近 7 天活跃用户的交易金额"，系统需要理解"活跃用户"对应 `dwd_user_active` 表，"交易金额"对应 `dwd_trade` 表的 `gmV` 字段（而非 `amount` 或 `total_price`），且隐含的关联键是 `user_id`。

现有的通用检索技术（如 Elasticsearch）无法处理数据领域的特殊复杂性：Schema 与业务语义的鸿沟（字段名 `amt` 实际表示"实付金额"）、多模态信息融合（表名、字段注释、Sample Data、血缘上游、甚至 ETL 代码中的注释）、以及需求-资产的跨域对齐（业务语言"留存率" vs 技术字段 `retention_rate`）。由于找表错误会导致后续全部分析失效（Garbage In, Garbage Out），对召回准确率要求极高。

本项目旨在联合高校顶尖 AI 力量，攻克大规模数据资产的语义理解与需求对齐难题，构建支持自然语言到数据资产映射的智能检索引擎。

预计产出

- 1) 提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。（围绕表语义向量化表示、业务-技术语义对齐算法、多模态数据资产索引构建等核心创新点）
- 4) 算法原型：交付一套百万级表规模的智能检索系统（包含语义索引构建、查询理解、候选排序模块）及完整源代码，支持自然语言到数据资产的端到端检索。
- 5) 技术指标：
 - 检索准确率：Top-5 命中率（用户所需表在 Top-5 中）不低于 85%；Top-1 准确率不低于 60%
 - 语义对齐准确率：业务术语（如"GMV"）到技术字段的映射准确率达到 90%以上
 - 检索延迟：单次查询响应时间（P95）不超过 500ms（百万级表规模下）
 - 索引新鲜度：新表创建后，可被检索的延迟不超过 5 分钟
 - 数据产出：构建不少于 1000 条高质量的 基于蚂蚁实际生产环境的 "自然语言查询-目标表" 的题库。

[返回首页](#)

21. 针对强化学习场景的混合线性模型推理优化研究

研究背景

随着大语言模型（LLMs）和强化学习（RL）技术的深度融合，如何高效优化 RL 训练过程中的大模型推理成为关键挑战。

现今各种线性注意力模型呈现百花齐放的场景，虽然在长序列上体现出了较传统 Transformer 更优的推理效率，但在短序列、前缀复用等场景仍然有很多不足。

本课题面向强化学习中的混合线性模型推理进行软硬协同、深入优化探索。

- 1) 推理需求：面向长序列、大规模混合线性模型和数据，结合并行计算、软硬结合优化等，提升模型推理性能，提升吞吐；
- 2) 推理-训练协同优化：探索混合线性模型推理结果如何反馈至 RL 训练过程，探索训推协同的推理优化。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文至少 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：提出 1-2 种针对 RL 任务的大模型推理优化技术；
- 5) 技术指标：在典型 RL 任务中实现显著效率提升（如吞吐量 $\uparrow$ 30%，延迟 $\downarrow$ 50%）。

[返回首页](#)

22. 基于观测数据的风险响应算法研究

研究背景

用户在不同授信额度下的风险曲线刻画一直是信贷风险管理领域算法的重要研究课题，了解不同类型客群自然的风险响应情况，对于制定差异化的客群额度策略有直接的意义。由于业务侧的考量以及成本的限制，很多时候难以直接在线上投放大规模的，基于额度供给的随机测试样本，因此如何使用线上实际的生效（观测）数据或小规模的测试数据来进行建模有很大挑战，需要从样本纠偏、小样本学习等角度构建通用的风险响应模型，提升模型对于风险曲线刻画的精准度。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：完成基于观测数据自然的风险响应的算法设计，交付一套针对非随机实验（Non-RCT）环境下观测数据偏置修复和多维度风险曲线刻画适用的因果效应评估的证架，及其源代码、权重等 checkpoint。
- 5) 技术指标：研究基于反事实推理因果推断方法，提升风险曲线单调性与拟合准确率，形成可解释的客群额度响应函数图谱。探寻适用于信贷额度敏感度分析与自动决策优化。在开源数据集上 AUUC 或 Qini 系数提高 10%~15%，在蚂蚁和/或其关联公司消费信贷场景落地，与现有算法相比反事实预测的均方根误差（RMSE）平均缩短 15%以上。

[返回首页](#)

23. 规约驱动的可信智能编程框架:融合领域知识注入与检索增强的幻觉抑制研究

研究背景

近年来，以大语言模型（Large Language Models, LLMs）为代表的人工智能技术在软件开发与数据交互领域展现出巨大潜力。基于自然语言生成结构化程序（如通用代码、SQL 查询）的智能编程系统（如 GitHub Copilot、CodeWhisperer、Text-to-SQL 工具）正逐步融入开发者工作流，显著提升研发效率与数据访问便捷性。然而，面对更为复杂的场景，如涉及支付宝内部复杂的业务逻辑、数据管理和系统架构的企业级场景，现有系统仍面临可信性不足的核心瓶颈，严重制约其规模化落地。

具体而言，当前 LLM 驱动的结构化生成存在两大共性挑战：

1) 语义漂移与事实幻觉问题突出。

LLM 在生成代码或 SQL 时，常因缺乏对任务规约（如接口契约、数据库 Schema、业务约束）的精准理解，产生逻辑错误、语法无效或语义偏离的输出。例如：

- 在数据智能研发任务中，通用大模型缺乏对内部术语、字段注释、口径文档的理解能力，生成结果常偏离业务真实含义；
- 在 AI 编程场景中，模型可能调用不存在的 API、忽略异常处理，或生成存在安全漏洞（如 SQL 注入、越权访问）的代码。

此类“幻觉”（Hallucination）较常产生。

2) 上下文知识利用浅层，缺乏领域适配能力。

现有方法多依赖通用预训练语料，难以有效融合结构化外部知识（如数据库元数据、API 文档、项目代码库、业务规则库）。尤其在企业级场景中，系统需同时理解静态规约和动态知识等，缺乏对这类知识的深度协同，导致生成结果虽“语法正确”，却“语义无效”或“无法集成”。

为应对上述挑战，规约驱动（Specification-Driven）范式正成为国际学术界与工业界的新共识。一方面，SDD（规范驱动开发）通过逐步细化文档来驱动 AI 编码的模式显得尤为适合。它能够帮助开发者将复杂的系统需求结构化地表达出来，为 AI 提供更准确、更完整的指引，从而在代码生成场景中发挥独特价值。另一方面，我们将深度整合支付宝业务资产，包括代码库、知识库、配置和线上运行状态等。确保 AI 产出的代码和方案严谨且贴合业务，真正满足需求。

与此同时，知识增强（Knowledge Augmentation）与幻觉抑制机制（如检索增强生成 RAG、执行反馈闭环）被证明可显著提升生成质量。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利不少于 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：完成规约驱动的可信智能编程框架的算法设计，交付一套面向企业级代码生

成与 Text-to-SQL 场景的规约感知生成架构及其源代码、模型权重等 checkpoint。

- 5) 技术指标：研究基于规约建模、领域知识注入与检索增强生成（RAG）相结合的幻觉抑制方法，提升代码/SQL 生成的语义正确率与业务合规率，形成可复用的规约驱动智能编程技术体系。探寻适用于企业级复杂业务场景下结构化程序生成的可信增强路径。在 Spider、Bird、HumanEval 等开源基准数据集上，目标任务准确率相较基线提高 10% 以上；在蚂蚁和/或其关联公司数据智能研发及 AI 编程场景落地，与现有算法相比，代码/SQL 生成幻觉率平均缩短 20%，生成结果一次性采纳率提升 15%。

[返回首页](#)

24. 基于博弈论的区块链信用系统防共谋机制研究

研究背景

随着区块链技术在信用系统中的广泛应用,信用背书机制已成为分布式信用体系的核心组件。在芝麻分等信用评分系统中引入信用背书机制,允许用户 A 为用户 B 的履约能力提供担保,这种设计虽然有效促进了信用传播和价值创造,但也为系统安全带来了严峻挑战——共谋攻击。

共谋攻击表现为多个恶意参与者通过串通合谋,构建虚假的信用背书链条,人为抬高信用评分,骗取系统奖励,最终导致信用体系的失效。在现有区块链信用系统中,这种攻击呈现出组织化、智能化的特征:攻击者利用系统的匿名性和自动化特性,组建"信用工厂"批量生产虚假背书;通过复杂的策略规避简单的检测机制;甚至利用博弈规则中的漏洞实现"合法作弊"。

传统中心化信用系统依赖人工审核和集中式风控来应对共谋,但这与区块链的去中心化理念相悖。而现有的区块链信用系统大多缺乏有效的防共谋机制,或仅采用简单的经济惩罚,无法从根本上解决理性参与者的策略性共谋行为。因此,亟需从博弈论的角度出发,设计一套与区块链特性深度融合的防共谋机制,确保信用背书系统的长期稳定和可信运行。

预计产出

- 1) 报告:提交项目结题表,提交结项验收报告。
- 2) 论文:投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录,提供论文底稿及收录邮件。
- 3) 专利:乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项,交付符合本项目创新点的专利申请号和专利申请相关材料。(内容关于防共谋识别与博弈机制)
- 4) 算法原型:交付一套针对社交背书场景的防共谋识别算法原型、底层源代码及模型训练 checkpoint。
- 5) 技术指标:研究基于图博弈的共谋检测方法,在蚂蚁社交背书场景落地,相比现有算法使共谋团伙识别准确率提升 15%以上,风险链路识别时延缩短 20%,有效支撑万亿级信用节点的实时风控需求。

[返回首页](#)

25. AI 眼镜音频相关技术研究（支持金额不超过 50 万元）

研究背景

智能眼镜发展迅速，市场自 24 年以来呈现快速发展趋势，销售量已初具规模，未来 2-5 年将来会成为个人终端重要的入口。

目前，蚂蚁已与多家眼镜厂商合作开发扫码支付、看设备支付方案，已经在市场上取得先发优势。

在眼镜使用场景中，由于眼镜交互方式的限制，语音交互功能将成为重要的交互方式，如用户使用语音命令唤醒扫码支付，使用语音输入付款金额，使用语音完成交易等。目前各家厂商在语音前端处理方案中能力参差不齐，给后端的 ASR 及意图带来极大的挑战。目前我们已经开发了一套眼镜中的麦克风处理算法，已经在一定程度上提升语音交互效果。但是部分厂商无法接入自研算法，对于近距人声干扰场景，还是不能有效抑制，会影响交易体验。

我们发起这个合作，借助于优秀高校资源，发起 AI 眼镜音频技术研究，希望在个性化降噪（如声纹降噪）、多模态降噪（mic+vpu+其他传感器）、开放声场（如防漏音）等方面进一步提升音频效果，提升用户体验。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文或专利：论文或专利 1 篇。其中，论文须为 CCF-A 类及蚂蚁认可的期刊/会议论文并最终收录，提供论文底稿及收录邮件。专利为乙方协助蚂蚁和/或其关联公司提交国内、国际专利，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 3) 算法原型：算法设计文档 x1；算法源码（C++）x1；模型文件 x1；模型训练代码（python）x1。
- 4) 技术指标：个性化降噪：近距非主讲人干扰平均抑制力度>20dB；ASR 错误率减少 30%。

[返回首页](#)

二、超算与智算（支持金额不超过 30 万元/项）

1. 软硬协同的大规模 KVCache 系统

研究背景

蚂蚁拥有丰富的 LLM 推理场景，如阿福、灵光、蚂蚁财富等 app 背后都有大模型支撑。随着 agent 类应用（Claude Code、OpenClaw 等）火爆，代码类大模型服务（如 GLM-5、Kimi K2.5 等）供不应求，高峰时期 TTFT 甚至超过 10 分钟，影响用户体验。仅扩资源的方式不仅会增加成本，而且无法很好适应业务波峰波谷的特性。Agent 类应用特点是请求具有超长上下文，但多次请求间存在大量重复计算，缓存复用率高达 90% 以上，因此可通过以存代算的方式来降低成本。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利不少于 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：支持主流 LLM 架构（DSA, Hybrid, MLA, GQA）KVCache 复用；支持不同量化格式（fp8/fp4/tensorquant）
- 5) 技术指标：
 - 平均 KVCache 命中率：通用场景达到 70%以上，Code Agent 场景 KVCache 命中率达到 95%以上；
 - 命中收益率：Cache 命中时 TTFT 指标相比直接计算下降 90%以上，长文本推理成本降至 10%以下；
 - 开源社区线下 meetup 活动 1~2 次。

[返回首页](#)

2. 面向多模态模型视觉的 Token 压缩

研究背景

当前多模态大模型在图片/视频等视觉场景下面临两大瓶颈：其一，视觉 Token 随分辨率与帧数线性增长，KV Cache 占用与显存/内存压力显著上升；其二，超长输入导致解码计算量与时延增加，推理吞吐下降。现有序列压缩研究主要面向纯文本，直接迁移到视觉往往造成感知与指令跟随能力回退。相比文本，视觉信号具有更强的空间与时间冗余，通过重要性建模与结构化合并，可在保持效果的同时实现更高压缩比，具备明确的工程落地价值。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：提供算法原型可验证实现。
- 5) 技术指标：算法效果精度损失小于 1%，推理业务端到端时延降低约 15% - 30%。

[返回首页](#)

3. 基于高效显存分配和 SLO-aware 请求调度的大规模 LLM 推理服务系统

研究背景

据摩根斯坦利预测，2025 年对 GPU 硬件的支出将达到 3000 亿美元，但大量昂贵的硬件却未被充分利用。AI 推理工作负载的 GPU 利用率通常徘徊在 20-40%，远低于训练任务。低 GPU 利用率的原因：

- 动态负载需要为峰值负载配置资源，AI 流量负载随时间变化极大，为保证服务质量（QoS），系统必须配置以适应峰值流量，导致非峰值期间资源闲置。
- 更大的 GPU 运行更小、更高效的模型，随着 GPU 性能的大幅提升和小型模型在特定任务中的优异表现，小型模型难以充分利用 GPU 容量。
- 一个模型占用一个 GPU（静态 GPU 分配）效率低下，目前的 GPU 仍采用基于预留的分配模型，通常将整个 GPU 分配给特定模型，即使在空闲期间，资源也无法被其他模型使用。

技术方案

- 设计一种高效的 GPU/NPU 显存管理抽象，实现推理模型权重、kvcache 的按需分配和释放，使得单 GPU/NPU 支持更多的推理模型实例，将 GPU/NPU 显存利用率提升到 90%+。
- 设计一套多模型推理服务调度框架，支持多推理模型服务动态工作负载中灵活的资源分配，提高成本效率并满足模型 SLO。

参考文献：

kvcached: <https://github.com/ovg-project/kvcached>

prism: <https://github.com/Multi-LLM/prism-research>

Aegaeon: <https://zhuanlan.zhihu.com/p/1964753682739463107>

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 2 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 技术指标：GPU/NPU 显存利用率提升至 90%+，模型推理成本降低 70%。

[返回首页](#)

4. 基于 Compute Express Link (CXL) 的智能计算系统架构优化与资源池化技术研究

研究背景

随着人工智能和大模型技术的快速发展，传统通智算计算架构中心面临几大核心挑战：

1) 通算：

内存容量瓶颈：科学计算应用内存需求年均增长 68%，远超 DDR 插槽扩展能力；

资源僵化问题：CPU 与内存固定配比导致平均利用率不足；

异构协同困难：FPGA/GPU 等加速器与 CPU 内存系统存在语义鸿沟。

2) 智算：

内存墙问题：GPU 显存容量限制导致大模型训练需频繁数据交换；

资源碎片化：CPU/GPU/内存资源固定配比造成利用率不足；

异构协同瓶颈：CPU 与加速器间数据搬移开销占训练时间 30% 以上。

Compute Express Link (CXL) 作为新一代高速互连协议，提供：内存语义一致性 (CXL.mem)；设备发现与管理能力 (CXL.io)；缓存一致性协议 (CXL.cache)。

该技术保持 CPU 内存空间和附加设备上内存的一致性，允许资源共享，解决 CPU 和设备，设备和设备之间的 memory 鸿沟从而获得更高的性能，降低软件栈的复杂性，降低整体系统成本。

该项目的目标是在蚂蚁的通算，智算环境中构建基于 CXL 的资源池架构。

能够实现通算的 CPU 和内存解耦，实现内存去重和热加载，探索智算环境下 HBM 的 offload，探索大模型显存扩展至 TB 级。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 2 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 技术指标：完成计算原型的验证，大模型显存 offload 至 TB，并产出相应的代码，测试报告，工程实现，性能上在同等业界水平有突破。

[返回首页](#)

5. 通信计算 Overlap 自动编排框架

研究背景

分布式训练与推理系统依赖高性能通信，通信与计算的重叠（Overlap）是提升系统性能的有效手段。然而，现有通算 Overlap 方案通常需要深度改造训推框架，并针对不同模型/并行策略手动编排调优（如 DBO），或分别改造计算与通信算子（如 SBO）。上述方案存在开发复杂度高、适配成本大的问题，难以快速支持多样化的模型结构与硬件平台。

也有一些框架（如 Triton-distributed）基于编译技术，提供高层次编程模型以实现通算 Overlap，有效提升开发效率。但其在一些场景与硬件上相较原生算子性能较低，导致整体效果不佳。此外，通算 Overlap 的编排工作高度依赖专家经验，借助 AI Coding（如领域 Agent Skills）辅助算子编排具有较大潜力，但尚缺乏系统性的探索与实践。因此，亟需一种通算 Overlap 自动编排框架，在保证通算 Overlap 效果的前提下，提升开发效率。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：通算自动编排框架及典型模型/并行策略下通算 overlap 算子实现。
- 5) 技术指标：降低分布式训练/推理通信耗时 50%+，实现小时级别通算 overlap 算子自动生成。

[返回首页](#)

6. 大规模异构场景大模型推理 serverless 调度优化

研究背景

随着大模型的能力提升以及 Agent 在各个领域的发展和落地，LLMs 的快速发展对集群计算能力的需求急剧增加，往往超出了现有资源的供应能力。

降低推理的成本不仅可以帮助企业降低数据中心的总拥有成本（TCO），也是企业在 AI 业务中快速低成本试错的关键因素，成为了企业的核心竞争力。

从模型部署的资源调度来看，当前的 LLM 应用通常采用巨大的静态资源分配，这迫使用户长时间等待任务队列，或不得不采购昂贵的硬件来满足需求，存在巨大的供需矛盾。

通过 serverless 技术按需付费和自动伸缩的架构特征，把资源分配从静态模式转变为动态分配，并机会性地（opportunistically）汇集随时可用的资源，避免不必要的排队和昂贵的 GPU 采购，不仅是一个重要的研究方向，也是提升资源利用率和实现动态弹性，大幅降低 LLM 服务部署的 TCO 的重要措施。

在大模型推理场景采用 serverless 架构面临着新的技术挑战，包括模型参数增加导致启动耗时高；LLM 服务的可扩展性并非线性：用户数量的增加可能导致成本指数级上升、延迟增加；请求之间差异性较大，不同请求的 tokens 数量和算力消耗可能会相差 1-2 个数量级；请求 SLO 要求多样，包括 TTFT/TPOT、长上下文、吞吐等。

总的来说，推理场景的 serverless 架构研究和探索对于 LLM 推理成本下降有巨大的帮助，但同时也有非常多的挑战。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利至少 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：完成大模型推理的基于流量自动弹性算法设计，交付一套适用于 vllm/sglang 等推理引擎和 LLM/VLM 文本/多模态的 serverless 分布式框架。
- 5) 技术指标：基于 serverless 推理技术，在蚂蚁生产实际的数据集上（至少覆盖 3 种模型），单位卡时能够处理的 tokens（TPM/卡/时）能够提升 10%+。

[返回首页](#)

7. 通智算融合场景下节点健康评估模型研究

研究背景

随着人工智能技术和云计算基础设施的持续演进,算力中心已从单一支撑通用计算业务,逐步发展为同时承载通用计算与智能计算任务的综合算力底座。作为算力供给的基本单元,节点的健康水平、性能稳定性和资源可用性直接影响任务运行效率、服务交付质量以及整体平台的稳定性。

在通用计算场景下,节点通常承载在线服务、批处理任务、容器应用等多样化负载,节点异常可能带来服务抖动、任务失败、时延升高、资源冗余增加等问题;而在智能计算场景下,尤其是大规模分布式训练和高并发推理任务中,业务对节点性能一致性、设备稳定性、通信效率和持续可用性的要求更为严苛,单个节点的性能退化或故障往往会被系统级放大,导致训练停滞、算力空转、时延恶化甚至任务整体失败。因此,尽管不同场景对节点健康的敏感方式有所差异,但节点服务质量始终是影响算力平台运行成效的核心因素。

当前,节点健康评估仍主要依赖 CPU/GPU 利用率、温度、内存、磁盘、网络等基础监控指标。此类指标虽然能够反映设备运行状态的部分表象,但对于复杂故障的关联识别、隐性异常的提前发现、性能退化趋势的判断以及节点服务质量的统一量化仍存在明显不足,难以满足通算与智算混合场景下对节点精细化治理和智能化调度的需求。

因此,亟需构建一套面向统一节点对象、兼顾通用计算与智能计算场景特征的健康评估模型,对节点运行状态、性能稳定性、资源有效性及业务承载能力进行综合量化评估,从而为节点准入管理、任务调度优化、异常预警和稳定性治理提供有力支撑,全面提升算力基础设施的韧性、效率与服务水平。

预计产出

1) 报告:提交项目结题表,提交项目结项验收报告。报告内容包括项目研究背景与目标、节点健康模型设计、关键指标体系、算法方案、实验评估结果、实际落地情况及后续优化建议等。

2) 论文:围绕本项目面向通用计算与智能计算场景的节点健康评估模型、节点服务质量量化方法及异常识别技术,投稿认可的期刊/会议论文 1 篇并最终收录,提供论文底稿及收录邮件。

3) 专利:乙方协助蚂蚁和/或其关联公司提交国内和/或国际专利 1 项,交付符合本项目创新点的专利申请号和专利申请相关材料。专利方向包括但不限于面向通用计算与智能计算场景的节点健康评估方法、基于多维信号融合的节点服务质量评分与异常预警方法。

4) 算法原型:完成面向通用计算与智能计算统一节点对象的健康评估算法设计,交付一套适用于节点健康度量、异常识别与服务质量评分的算法框架,及其源代码、模型参数/规则配置、测试样例和部署说明。该算法原型支持节点健康状态综合评估、节点健康分数计算、异常识别与风险预警,并具备与调度、主动运维等场景结合的能力。

5) 技术指标:研究基于多源监控数据、日志事件、资源利用率和性能稳定性特征融合的节点健康评估方法,构建统一的节点健康分数计算体系,形成面向通用计算与智能计算场景的节点健康评估方案。探寻适用于异构算力环境下节点服务质量量化、异常识别和风险预警的方法,并在开源数据集及蚂蚁和/或其关联公司实际场景中完成验证与落地。

具体指标如下：

- 在开源数据集或公开可验证样本上，节点异常识别准确率较基线方法提升 10%以上；
- 在蚂蚁和/或其关联公司场景中完成节点健康分数计算框架落地，形成可用于调度和主动运维的评估结果；
- 与现有规则型或单指标评估方法相比，节点异常发现平均提前时间提升 20%以上；
- 在典型应用场景下，辅助问题定位或处置平均耗时缩短 15%以上。

[返回首页](#)

三、网络空间安全与隐私保护（支持金额不超过 30 万元/项）

1. 基于大模型的自动化威胁验证技术研究

研究背景

随着软件供应链和开源组件广泛引入，外部威胁情报、漏洞报告与内部代码资产之间的关联验证愈发困难。现有研判主要依赖专家人工分析，存在理解链条长、验证成本高、覆盖不足、响应滞后等问题，难以支撑企业场景下的快速处置。蚂蚁可提供威胁情报分析、漏洞研判、代码与依赖影响定位、验证结果回流等真实场景。本课题拟利用大模型的自然语言理解、代码语义解析与上下文推理能力，构建多源威胁情报自动化验证方法，实现对威胁真实性、触发条件和影响范围的高效判定。

本课题面向多源威胁情报自动化验证需求，重点突破威胁情报语义理解、验证环境自动构建和威胁真实性动态判定等关键问题，形成从情报解析、条件推断、脚本生成到执行验证的完整技术方案。项目拟构建可在蚂蚁实际场景中落地的技术原型，实现对外部威胁情报的自动解析、验证与评估，准确判断相关威胁在内部环境中的存在性、可利用性及潜在影响范围。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1-2 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：交付威胁情报自动验证与 DevSecOps 实时检测大模型推理原型系统。
- 5) 技术指标：准确率/延覆盖率等核心量化指标。

[返回首页](#)

2. 面向多模态触发与动态植入的大模型后门防御技术研究

研究背景

后门攻击作为一种极为隐蔽的威胁，攻击者通过污染训练数据、微调篡改模型权重或污染检索增强生成（RAG）系统的知识库，将恶意触发逻辑植入模型。这使得模型在绝大多数正常查询下表现合规，仅在遇到特定、隐蔽的触发条件（如特定关键词、符号或问题范式）时，才会偏离设计目标，输出虚假信息、有害内容或绕过安全限制。由于后门在常规测试中难以察觉，一旦在生产环境被激活，可能对业务和用户造成重大且难以追溯的损失。因此，针对这种“潜伏式”攻击的检测与防御技术，已成为大模型安全部署的迫切需求。

面向业界主流大模型，研究其面临的新型后门攻击模式与防御技术。重点研究通过数据投毒、权重篡改及检索系统（RAG）等外部组件植入的隐蔽后门，探索其触发机制与内部表征特性，借助知识编辑、动态行为监测、触发模式识别等前沿技术，构建覆盖模型全生命周期的防御体系，具体可以包括：

- 1) 大模型训练前阶段的数据投毒检测技术，面向文本、图像、音频等多模态输入数据，实现对污染数据的主动发现与清洗；
- 2) 大模型训练后阶段的离线后门扫描技术，定位对特定触发模式异常响应的关键节点；
- 3) 大模型推理阶段的动态后门检测和防御技术，实时分析输入输出间的逻辑一致性，监控并拦截偏离基线的异常激活模式，有效防御外部组件（RAG）带来的动态植入威胁。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文至少 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：完成大模型后门检测与防御的算法设计，交付一套完整的大模型后门检测与防御技术框架，一份后门攻击基准测试数据集与评估方法。
- 5) 技术指标：完成在至少一个核心业务场景下的验证与落地。

[返回首页](#)

3. 大模型防蒸馏对抗与核心知识资产动态防护技术研究

研究背景

大语言模型的训练依赖海量数据与算力，研发成本极高。恶意竞争者无需投入巨额资源，只需批量获取模型返回数据，即可通过蒸馏手段低成本复现模型能力，严重侵蚀原创者的技术资产与市场竞争优势。随着大模型成为关键生产要素，此类窃取已引发监管与产业界的高度关注。构建防蒸馏能力，直接关乎企业核心技术资产安全、市场格局稳定及 AI 产业健康可持续发展，具有显著价值。

本课题聚焦三大研究方向：

1) 蒸馏攻击全链路对抗技术

覆盖机器流量实时检测、提示词注入拦截、蒸馏意图识别及风险实体画像，实现事前-事中-事后一体化防护。

2) 核心知识资产分级防护策略

面向链式思维（CoT）、外挂知识库、领域训练数据、系统提示词等高价值资产，构建差异化、可扩展的多场景防护方案。

3) 慢速蒸馏攻击检测

针对攻击者通过降低请求频率、拉长访问间隔、轮换账户/IP 等手段模仿正常用户行为的隐蔽模式，设计高灵敏度、低误报的检测机制。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文不少于 1 篇并最终收录，提供论文底稿及收录邮件，覆盖检测算法与防护策略。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1-2 项，交付符合本项目创新点的专利申请号和专利申请相关材料，覆盖检测算法与防护策略。
- 4) 算法原型：实现可落地的蒸馏攻击防护模型，支持多攻击模式检测；构建覆盖提示词注入、慢速蒸馏等攻击模式的评测数据集，建立可重复、可对比的基准测试方案。
- 5) 技术指标：完成金融、医疗等至少一个核心业务场景下的原型验证与落地。

[返回首页](#)

4. 智能化多语言程序分析关键技术研究

研究背景

程序分析技术是保障蚂蚁数亿应用安全的重要技术，随着 AI 技术的快速发展，一方面，AI 加持的智能化程序分析技术逐渐发挥重要作用，尤其是 AI 强大的语义理解能力和泛化能力，以及较低的支持成本，可以和传统程序分析技术形成良好的互补。另一方面，AI 原生的安全风险也给传统程序分析技术带来了一些的技术挑战。

本项目希望能探索：

- 1) 在 AI 时代，程序分析技术和 AI 的能力边界，哪些场景适合使用传统程序分析技术，哪些场景适合使用 AI，传统程序分析技术可以给 AI 提供哪些原子化的能力以提高智能化的能力上限，以及如何衡量。
- 2) 面对 AI 原生的新的安全风险，智能化程序分析技术在其中可以发挥的作用。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 2 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 2 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：程序分析技术+AI 的多语言代码审计原型系统一个；代码审计领域的 AI 评测 Benchmark 一个。
- 5) 技术指标：
 - 代码审计原型系统：至少覆盖 Java 和 Python 2 种语言，至少覆盖 5 种常见 Web 漏洞和 3 种常见 AI 原生安全风险的检测能力，在 Benchmark 上召回率不低于 90%，误报率低于 10%。
 - Benchmark：至少覆盖代码审计领域 Java 和 Python 2 种语言，每种语言的评价数据集至少 200+子场景/评价项，数据集准确率 99%以上，每个 case 能对应到评价项。针对 Top5 模型，在 Benchmark 上得分中位数<50（满分 100），模型间区分度>40%，评测结果与代码审计原型系统表现的相关性>90%。

[返回首页](#)

5. 零知识证明友好的分组密码设计

研究背景

零知识证明友好的分组密码在数字签名、零知识证明友好的哈希函数、可验证加密等领域具有重要的应用价值。针对现有分组密码与零知识证明耦合性能差的问题,设计高安全性、易算术化的分组密码算法。要求算法面向 256 比特安全性设计;鼓励提供多个安全性级别配置。要求算法步骤能够高效表示为二进制(扩)域上的运算,算子包括异或、与、移位、比特重排、二进制扩域上的加法和乘法等;要求与和乘法操作数目少、幂次低,避免无法代数表示的查找表和整数模加法。要求算法支持伪随机生成器的构造。

本研究涉及分组密码和零知识证明两个密码学方向的科学研究,具有明显的交叉性与前沿性,需要通过深入、系统性的学术研究来验证可行性,以便决定是否将成果付诸应用于后续的上层研究中。

预计产出

- 1) 报告:提交项目结题表,提交结项验收报告。
- 2) 论文:投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录,提供论文底稿及收录邮件。
- 3) 算法原型:设计一套零知识证明友好的分组密码算法,并提供详尽的安全性分析报告。
- 4) 技术指标:用于零知识证明方案时,同等情况下对比 FAEST(基于 AES)可取得 25% 以上效率提升。

[返回首页](#)

6. 面向区块链资产安全的智能体驱动型安全分析与风险治理研究

研究背景

随着蚂蚁数字科技区块链与 Web3 业务的深入推进，链上资产从金融标准化产品向新能源、算力、供应链等复杂实体资产持续延伸，链上代码安全的重要性愈发突出。近期，以大语言模型为核心的 AI 智能体在代码理解、推理与自主决策方面取得显著进展，可扮演代码解析、漏洞推演与修复等重要角色。本课题拟以智能体驱动为技术手段，探索链上程序安全分析与风险治理方法的新范式。

技术挑战：

- 1) 复杂业务逻辑与跨模块交互解析：链上金融协议合约嵌套与跨文件调用极深，单一模型解析闪电贷、重入、抢跑等攻击逻辑时极易发生上下文断裂，难以构建全局资金流转图谱。
- 2) 智能体推理稳定性与一致性：智能体在攻击路径推演及结果归纳时，可能受上下文不完备或提示噪声影响，导致结果偏差乃至逻辑发散。
- 3) PoC 动态验证与误报消除：现有方法难以判断漏洞可利用性，亟需在受控环境中动态验证并通过执行反馈降低误报率。
- 4) 漏洞经济损失量化困难：链上资产价值动态波动、交互关系复杂，如何在沙盒中结合实时流动性与资产价格评估实际财产损失，尚缺成熟方案。
- 5) 自动修复的目标对齐与安全约束：现有方法易陷入“目标偏移”，漏洞未除却保留原生逻辑，确保修复安全且无次生风险是核心难点。

综上，智能体驱动的链上程序审查与修复面临诸多新挑战，亟需构建高效、鲁棒的安全理论模型与分析系统。

具体目标：

- 1) 智能体协同架构设计与复杂逻辑解析：探索链上程序安全审查的智能体架构，设计代码解析、漏洞检测、修复等异构角色，捕捉跨模块动态调用关系，解决上下文断裂，确保协同推演一致性。
- 2) 基于受控执行环境的 PoC 动态验证：在接近真实链上状态的环境中对攻击路径进行实际执行验证，结合执行结果校验与修正检测结论；通过智能体辅助生成与优化 PoC，实现漏洞的动态确认与误报过滤。
- 3) 漏洞经济损失量化与影响评估：建立结合链上实时流动性、资产价格与程序状态的经济学量化模型，在沙盒验证环节自动化评估漏洞利用门槛及实际财产损失规模，作为确证漏洞有效性的关键依据。
- 4) 基于安全约束的漏洞等价修复机制：将多智能体协同修复重构为受限优化问题，以安全合规为硬约束、业务逻辑等价为优化目标，通过策略优化与动态反馈平衡补丁质量与安全性，稳定生成无次生风险的等价修复代码。
- 5) 针对性实验验证与系统交付：在公开及业务自有数据集上开展评估；检测任务关注召回率、误报率与响应速度，代码修复关注通过率与等价性。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料，专利保护范围涵盖链上程序漏洞检测、智能体协同分析、漏洞自动修复等关键技术模块。
- 4) 算法原型：完成面向区块链链上程序漏洞检测与修复的算法设计，交付一套支持多智能体协同分析、PoC 动态验证及 AI 生成代码安全审查的漏洞检测与修复原型系统源代码。
- 5) 技术指标：研究基于多智能体协同与动态验证方法，提升链上程序漏洞检测准确率，形成可落地的自动化审计与修复能力。在智能合约漏洞数据集上，漏洞检测召回率相比现有方法提高 5%以上、误报率降低 5%以上；在蚂蚁和/或其关联公司的区块链场景落地，与现有审计方案相比，漏洞检测响应时间平均缩短 10%。

[返回首页](#)

7. 面向复杂技术生态的自适应隐私数据检测系统研究

研究背景

在全球化与数字化进程中，隐私数据的自动化检测与治理已成为软件开发质量保障的关键环节。然而，当前业界在构建隐私数据检测能力时，面临三大核心技术挑战：

- 1) 隐私数据分类体系的动态演化：随着新技术尤其是人工智能相关业务场景的快速发展，隐私数据的界定范围与分类粒度不断演进。传统的基于固定规则库的检测模式难以适应这种动态变化，导致检测基准与实际需求之间存在显著滞后。
- 2) 隐私数据语义的多样性与异构性：不同业务场景、技术框架对隐私数据的命名规范与使用模式千差万别（例如，同一生物特征数据可能以多种字段名、多种存储形式存在于代码中）。将代码层面的具体数据操作与高层语义概念进行精准关联，是一项极具挑战性的映射任务。
- 3) 技术生态的碎片化：移动应用（Android/iOS）、小程序、快应用及智能终端（车机、手表）等技术栈迥异，其数据存取范式与 API 调用方式各不相同。构建一个能够跨平台、跨技术栈统一理解与抽象隐私数据操作的技术体系，是实现规模化自动检测的关键瓶颈。

为系统性地解决上述问题，本项目旨在突破传统静态规则的局限，核心研究如何利用大语言模型对隐私数据语义的深度理解能力，动态构建并维护一个可演进的隐私数据分类与识别体系。该体系将作为连接高层语义定义与底层代码实现的智能桥梁，为实现精准、高效、可扩展的自动化隐私数据检测奠定理论基础与技术支撑。

预计产出

- 1) 报告：提交项目结项验收表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：构建动态、可扩展的隐私数据分类体系；多模态信息提取与向量化，基于向量的关联完成合规判定。
- 5) 技术指标：在蚂蚁隐私合规检测业务场景中落地，覆盖集团应用上架、广告应用审核、监管整改和小程序隐私审核等多项业务，检测的准确率和召回率提升至 90%以上。

[返回首页](#)

四、软硬协同（支持金额不超过 40 万元/项）

1. 基于 GPU 的多密钥 CKKS 加速

研究背景

多密钥同态加密允许在同态加密计算中使用不同密钥分别保护输入数据和计算结果，是构建大规模复杂密文计算应用的重要基础。但是，随着密钥数量的增长，计算开销将快速增长，进一步降低同态加密计算系统的性能。针对多密钥同态加密实际应用的需求，需要对多密钥同态加密的加速技术开展研究。基于 GPU 的多密钥同态加密加速研究，有助于快速构建可用的多密钥同态加密加速技术原型，同时也有助于理解密钥数量增长对于底层硬件性能表现的影响，为后续相关硬件加速器的研究提供基础数据。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：参考 ACM CCS 2023 上的 Multi-Key CKKS(MK CKKS)算法（Asymptotically Faster Multi-Key Homomorphic Encryption from Homomorphic Gadget Decomposition），或其他更新的 MK CKKS 算法。
- 5) 技术指标：相较于优化前基于 CPU 的版本，基于 GPU 优化后的 MK CKKS 算法性能提升 100 倍以上；使用蚂蚁自研同态加密编译器、加速库、Benchmark 开展研究；提供软件源代码和技术文档。

[返回首页](#)

2. 基于多 GPU 的 FHE 加速

研究背景

随着全同态加密在隐私计算领域的应用走向纵深，如大模型（LLM）联邦学习、大规模基因测序等场景，数据规模与安全参数呈爆炸式增长。全同态加密涉及的高阶多项式运算和庞大的密文规模，不仅对计算吞吐量有极高要求，更触及了单张 GPU 的显存上限（Memory Wall），单卡性能已难以满足工业级实时性的需求。同时，GPU 与内存及 SSD 的数据交换也将显著影响同态加密应用在 GPU 上的性能表现。研究基于多 GPU 的加速方法是突破 FHE 应用瓶颈的关键。首先是资源维度的突破，通过多卡并行与分布存储，能够承载更大规模、更高深度的同态算路，解决复杂算法在大规模数据集上的适配问题。其次是性能的飞跃，利用多 GPU 间的高速互联（如 NVLink）优化数据分片与集体通信策略，可实现计算效率的线性扩展。这不仅能将原本耗时数小时的任务缩短至秒级，更是同态加密从实验室走向大规模工业化部署、支撑构建“隐私计算算力集群”的核心技术路径。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：基于 llama3-8B 与 CKKS 整合后的模型。
- 5) 技术指标：相较于现有基于多 GPU 的密文大模型推理加速方案，性能提升 2 倍以上；使用蚂蚁自研同态加密编译器、加速库、Benchmark 开展研究；提交软件源代码和技术文档。

[返回首页](#)

3. 面向同态加密的 CSD 功耗-性能协同优化方法

研究背景

可计算存储(CSD)是一种将算力引擎集成于存储控制器内部的革新架构,旨在通过“近数据计算”模式从根本上缓解海量数据在存储介质与主机内存间频繁迁移引发的 I/O 瓶颈。在高性能同态加密(FHE)加速系统中,CSD 被关键性地用于承载密文转置、重排列及大规模向量运算等访存密集型任务,通过在存储层级内实现数据预处理,显著分担了主机侧的内存带宽压力。然而,将 CSD 部署于高负载的 FHE 异构环境时,面临着性能表现与热功耗控制难以兼顾的严峻挑战:FHE 算子极高的计算强度会导致 CSD 控制器热量迅速积聚,从而频繁触发硬件热节流(Thermal Throttling)机制,因被迫降频而引发系统吞吐能力的剧烈波动与衰减。因此,深入探索面向同态加密加速场景的 CSD 性能与功耗协同调度策略具有重要价值,这不仅能够通过热感知的任务映射有效抑制过热导致的性能损失,更是推动隐私计算系统迈向高能效、长时稳定运行的核心技术路径。

预计产出

- 1) 报告:提交项目结题表,提交结项验收报告。
- 2) 论文:投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录,提供论文底稿及收录邮件。
- 3) 专利:乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项,交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型:基于 Samsung-Xilinx SmartSSD 及其参数开展研究
- 5) 技术指标:相较于优化前的方案,CSD 整体性能提升 70%以上;在研究中使用蚂蚁自研同态加密编译器、加速库、Benchmark;提供软硬件原型、源代码和技术文档。

[返回首页](#)

4. 面向全同态密文大模型推理的超节点异构近数据计算系统

研究背景

全同态密文计算从底层消解了大模型推理环节的敏感数据泄漏风险，成为构建智能体内生安全防御体系的关键技术路径。然而，全同态加密导致数据膨胀数十至数百倍，严重限制了大模型推理系统的多轮对话能力与并发规模；同时，海量密文的高效传输与加载成为瓶颈，数据迁移开销导致计算单元频繁空载，制约整体推理性能。机柜级超节点异构计算系统打破单节点规模限制，高效集成海量异构算力与内存、存储资源，已成为国内外头部企业破解 AI 计算性能挑战的重要架构方向。依托公司已有全同态密文计算硬件基础设施，融合成熟商用异构加速资源（GPU、FPGA）与公司自研密文计算加速芯片，在不改变现有 AI Infra 架构的前提下构建密文大模型推理超节点计算系统，是破解隐私数据信任难题并兼顾供应链安全可控的关键路径。为匹配全同态密文大模型推理在不同阶段对“算力-数据-带宽”的多维需求，亟需从算子并行、任务并行、加密方案并行等多角度探索异构近数据计算系统设计方案：将各类专用计算单元（商用 GPU、FPGA 及自研密文 ASIC 芯片）与海量 NVMe SSD 存储资源以多种方式组合并物理临近放置，削减跨设备数据迁移开销，降低传输延迟与带宽挤占。在此基础上，基于新兴互连技术（商用 DPU、内存语义交换芯片等）构建超节点异构计算系统，实现近数据计算组件的弹性扩展与高效协同，支撑海量密文数据下的高性能大模型推理需求。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：基于 llama3-8B 与 CKKS 整合后的模型。
- 5) 技术指标：相较于现有 DGX-H20 系统，性能提升 2 倍以上；使用蚂蚁自研同态加密编译器、加速库、Benchmark 开展研究；提交软件源代码和技术文档。

[返回首页](#)

5. 端云协同的同态加密、转密和解密计算性能优化

研究背景

同态加密的工作流程主要包含用户侧加解密和云端密文计算两部分。由于同态加密属于非对称密码体制，数据加密后会产生显著的密文膨胀（通常为明文的数十至数百倍），导致网络传输成本急剧上升。为了缓解这一问题，近期研究提出了混合加密方案：用户端先采用对称密码（如 AES）对原始数据进行加密以避免密文膨胀，密文数据到达云端后再通过专用协议在密态下转换为同态加密密文——这一过程被称为“转密”（transciphering），整个流程中明文数据始终不泄露，既保障了传输效率又满足了云端同态计算需求。然而，现有研究主要聚焦于云端密文计算的性能优化（如算子加速、内存管理等），对用户侧加解密过程以及转密环节的性能瓶颈关注不足。实际上，用户侧的加密延迟直接影响系统响应时间，解密过程的效率决定了结果获取速度，而转密操作作为对称密码与同态加密的桥接环节，成为端到端性能的关键制约因素。为此，本项目将系统性探索加密、转密和解密全流程的性能优化方法：研究面向资源受限用户设备的轻量级加密方案、设计高效的转密算法及其硬件加速架构、优化解密过程中的噪声管理与并行化策略，从而打通同态加密系统的端到端性能瓶颈，进一步提升其实际可用性和部署可行性，织密同态加密技术体系。

预计产出

- 1) 报告：提交项目结题表，提交结项验收报告。
- 2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件。
- 3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料。
- 4) 算法原型：基于 SoK: FHE-Friendly Symmetric Ciphers and Transciphering（CHES 2025）中介绍的转密算法开展研究
- 5) 技术指标：基于端侧设备（如：手机、平板或同类开发板）可完整运行加密和解密算法，并分析转密技术引入后对端侧计算性能和能耗的影响；基于 GPU 的转密算法，性能相较于 CPU 版本提升 100 倍以上；在研究中使用蚂蚁自研的同态加密编译器、加速库和 Benchmark；提交源代码和技术文档。

[返回首页](#)